

Reconhecimento de atividades humanas com IA embarcada em smartwatch

Professor:

Rodrigo Kobashikawa Rosa

Equipe:

Ana Carolina Dutra Ramos
Camila Gois de Jesus
Guilherme Magalhães Júnior



Reconhecimento de atividade humana com IA embarcada em smartwatch

DATASET UTILIZADO

WISDM

Smartphone and Smartwatch Activity and Biometrics Dataset

51	participantes	18	atividades no conjunto
20 Hz	frequência de coleta	6	sinais disponíveis

5 classes selecionadas

- A · Caminhar
- B · Correr
- C · Escadas
- G · Escovar dentes
- R · Bater palmas




Fonte: WISDM / UCI Machine Learning Repository - <https://archive.ics.uci.edu/dataset/507/wisdm+smartphone+and+smartwatch+activity+and+biometrics+dataset>

OBJETIVO/ PROBLEMA

Reconhecer atividades pelo movimento

Em vez de imagens ou áudio, o modelo interpreta sequências dos sensores do pulso.


A	Caminhar	Walking
B	Correr	Jogging
C	Escadas	Stairs
G	Escovar dentes	Brushing Teeth
R	Bater palmas	Clapping



OBJETIVO

EDA



Distribuição das classes e comportamento dos sinais de movimento



OBJETIVO

EDA


Distribuição das classes e comportamento dos sinais de movimento



MÉTODO

Do WISDM aos exemplos de treino

A preparação dos sinais é tão importante quanto a arquitetura da rede.




REGRA ESSENCIAL

Separar por participante antes de criar janelas evita vazamento de dados.

ENGENHARIA DE ATRIBUTOS

O modelo enxerga 5 segundos

Uma nova janela começa a cada segundo, permitindo previsões recorrentes.



EXPERIMENTOS ARQUITETURAIS

MLP | CNN

Arquiteturas comparadas

MLP - baseline

- Entrada 100 × 6
- Normalização
- Flatten: 100 × 6 vira um vetor de 600 valores
- Dense 64, ReLU
- Dropout 20%
- Dense 32, ReLU
- Dense 5, Softmax

CNN - Compacta

- Normalização
- Conv1D: 16 filtros, kernel 5, ReLU
- MaxPooling de tamanho 2
- Conv1D: 24 filtros, kernel 3, ReLU
- Global Average Pooling
- Dense 16, ReLU
- Dense 5, Softmax

CNN - Média

- Normalização
- Conv1D: 32 filtros, kernel 5
- MaxPooling
- Conv1D: 64 filtros, kernel 3
- MaxPooling
- Conv1D: 64 filtros, kernel 3
- Global Average Pooling
- Dense 32
- Dense 5, Softmax

CNN - Profunda

- Normalização
- Conv1D: 32 filtros, kernel 5
- Conv1D: 32 filtros, kernel 3
- MaxPooling
- Conv1D: 64 filtros, kernel 3
- Conv1D: 64 filtros, kernel 3
- MaxPooling
- Conv1D: 128 filtros, kernel 3
- Global Average Pooling
- Dense 64
- Dense 5, Softmax

Treinamento: Adam + Early Stopping · Saída: probabilidade para cada atividade

RESULTADOS E VARIÁVEIS

MLP | CNN

Resultados Avaliados

MLP - base line

- Parâmetros: 40.709
- Keras/FP32 accuracy: 76,93%
- Keras/FP32 macro-F1: 0,7671
- INT8 accuracy: 76,77%
- INT8 macro-F1: 0,7648
- Tamanho FP32: 162,89 KB
- Tamanho INT8: 46,73 KB

CNN - Compacta

- Parâmetros: 2.157
- Keras/FP32 accuracy: 83,94%
- Keras/FP32 macro-F1: 0,8377
- INT8 accuracy: 84,30%
- INT8 macro-F1: 0,8421
- Tamanho FP32: 14,66 KB
- Tamanho INT8: 10,70 KB

CNN - Média

- Parâmetros: 21.797
- Keras/FP32 accuracy: 82,88%
- Keras/FP32 macro-F1: 0,8290
- INT8 accuracy: 82,88%
- INT8 macro-F1: 0,8290
- Tamanho FP32: 92,88 KB
- Tamanho INT8: 35,23 KB

CNN - Densa

- Parâmetros: 55.941
- Keras/FP32 accuracy: 84,39%
- Keras/FP32 macro-F1: 0,8425
- INT8 accuracy: 84,77%
- INT8 macro-F1: 0,8464
- Tamanho FP32: 228,32 KB
- Tamanho INT8: 75,98 KB

Treinamento: Adam + Early Stopping · Saída: probabilidade para cada atividade

ARQUITETURA SELECIONADA

CNN 1D compacta: melhor equilíbrio para o embarque

Convoluções identificam padrões que se repetem ao longo dos sinais dos sensores.



Treinamento: Adam + Early Stopping · Saída: probabilidade para cada atividade

• 2.157 parâmetros • 83,73% accuracy INT8 • 0,8355 macro-F1 • $\approx 10,70\text{KB}$


EXPERIMENTO

Avaliação justa, por participante

Os dados de teste pertencem a pessoas que o modelo não viu durante o treinamento.



Observações importantes:




Para as outras atividades, foram:
Stairs - 83,18% | Clapping - 84,21% | Walking - 89,44% | Jogging - 99,71%

IA NO DISPOSITIVO

Da rede treinada ao modelo INT8

O objetivo é executar a inferência localmente no Galaxy Watch6 Classic.



Contrato do modelo

Entrada int8 [1,100,6] · labels fixas · mesma ordem de canais

PROVA DE VIABILIDADE

O que já funciona no Galaxy Watch6

O dispositivo real já recebeu nosso aplicativo e forneceu leituras de movimento.

VALIDADO NO RELÓGIO

- ✓ Pareamento via ADB concluído
- ✓ Aplicativo Wear OS instalado
- ✓ Acelerômetro X / Y / Z em tempo real



Objetivo final: classificar atividades sem processamento na nuvem.

Obrigado!

